

Optimization Methods for Learning

张海鹏

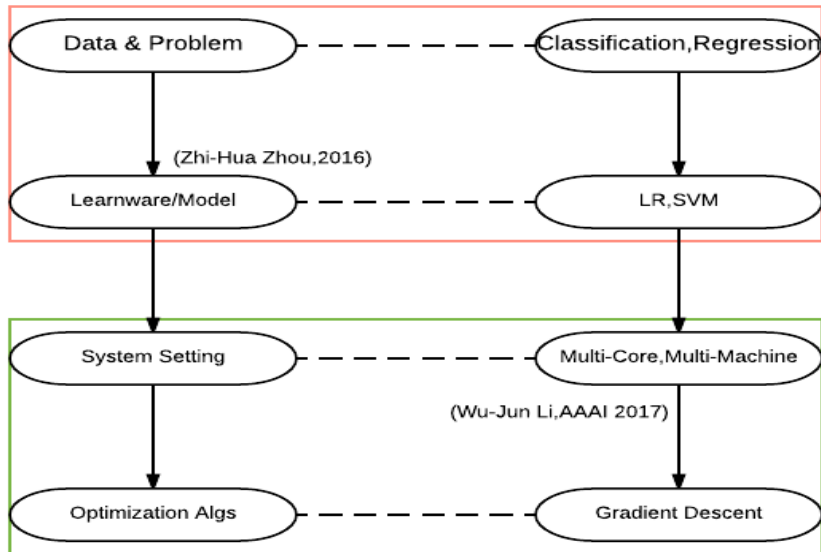
University of JiangNan

zhpmatrix@gmail.com

2017 年 4 月 20 日

- Optimization Methods for LR and Distributed Implementation
- Roadmap of Optimization Improvement
- Optimization Methods for Deep Learning
- Ideas
- PSO v.s. Gradient Optimization

Distribution Optimization:SGD-> HogWild!



Linear Regression-(BGD,SGD,mini-BGD)(1/3)

Model:

$$H_{\theta}(X) = \sum_{j=0}^N \theta_j X_j \quad (1)$$

Loss Function:

$$J(\theta) = \frac{1}{2M} \sum_{i=1}^M (H_{\theta}(X^{(i)}) - Y^{(i)})^2 = \frac{1}{M} \sum_{i=1}^M \frac{1}{2} (H_{\theta}(X^{(i)}) - Y^{(i)})^2 \quad (2)$$

Diff:

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{M} \sum_{i=1}^M (H_{\theta}(X^{(i)}) - Y^{(i)}) X_j^{(i)} \quad (3)$$

(T.Hastie,R.Tibshirani,J.Friedman,ESL,2.3.1,Linear Models and Least Squares)

Linear Regression-(BGD,SGD,mini-BGD)(2/3)

BGD:

$$\theta_j^{(t+1)} = \theta_j^{(t)} - \eta \frac{1}{M} \sum_{i=1}^M (H_{\theta^{(t)}}(\mathbf{X}^{(i)}) - \mathbf{Y}^{(i)}) \mathbf{X}_j^{(i)} \quad (4)$$


SGD:

$$\theta_j^{(t+1)} = \theta_j^{(t)} - \eta (H_{\theta^{(t)}}(\mathbf{X}^{(i)}) - \mathbf{Y}^{(i)}) \mathbf{X}_j^{(i)} \quad (5)$$

mini-BGD:

$$\theta_j^{(t+1)} = \theta_j^{(t)} - \eta \frac{1}{m} \sum_{i=1}^m (H_{\theta^{(t)}}(\mathbf{X}^{(i)}) - \mathbf{Y}^{(i)}) \mathbf{X}_j^{(i)} \quad (0 < m < M) \quad (6)$$


Linear Regression-(BGD,SGD,mini-BGD)(3/3)



Each thread draws a random example i from training data.

- ~~Acquire a lock on the current state of parameters $\theta^{(t)}$.~~
- Thread reads $\theta^{(t)}$.
- Thread updates $\theta^{(t+1)} = \theta^{(t)} - \eta(H_{\theta^{(t)}}(X^{(i)}) - Y^{(i)})X^{(i)}$.
- ~~Release lock on $\theta^{(t)}$.~~

Distribution-Performance



- Convergence
- Complexity
- Communication: throughput, latency

1. How to trade off accuracy and convergence?

BGD($O(\rho^T)$), SGD($O(\frac{1}{T})$).

2. How to choose learning rate?

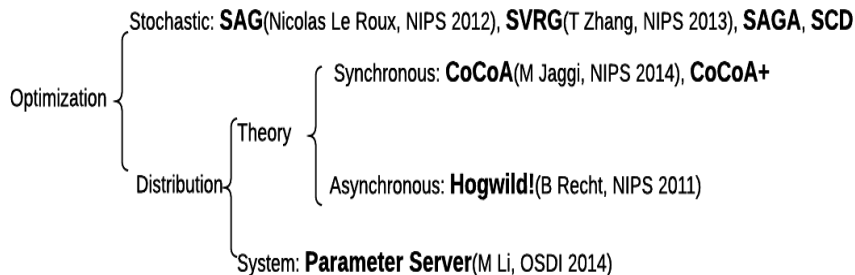
Fixed and Diminishing Stepsize.

3. How to escape saddle point in non-convex problem?

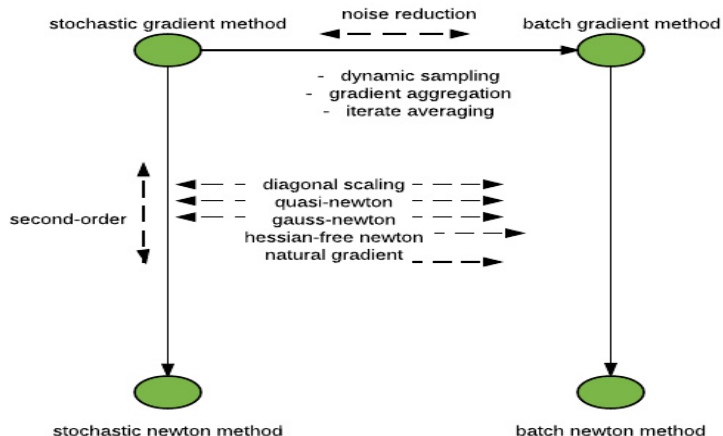
$$z = x^2 - y^2$$

4. How to make communication efficient in distribution setting?

Outline(1/3)-Overall

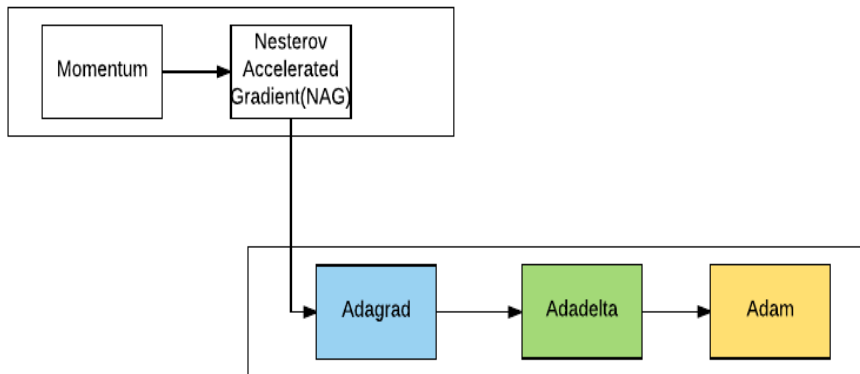


Outline(2/3)-SGDs





《Optimization Methods for Large-Scale Machine Learning》 (Bottou L, Arxiv,2016)

Outline(3/3)-DL




《An Overview of Gradient Descent Optimization Algorithms》 (Sebastian Ruder, Arxiv, 2016)

Momentum v.s. NAG(1/2)



(Source: Genevieve B. Orr)



(Source: G. Hinton's lecture)

Momentum v.s. NAG(2/2)

Momentum:

$$\nu_t = \gamma \nu_{t-1} + \eta \nabla_{\theta^{(t-1)}} J(\theta^{(t-1)}) \quad (7)$$

$$\theta^{(t)} = \theta^{(t-1)} - \nu_t \quad (8)$$

NAG:

$$\theta' = \theta^{(t-1)} - \gamma \nu_{t-1} \quad (9)$$

$$\nu_t = \gamma \nu_{t-1} + \eta \nabla J_{\theta'}(\theta') \quad (10)$$

$$\theta^{(t)} = \theta^{(t-1)} - \nu_t \quad (11)$$

Ada Algs(1/3)-AdaGrad

$g_{t,i} = \nabla_{\theta} J(\theta_i)$ 表示目标函数在第 t 步中在 θ_i 的梯度，则对传统 SGD 有：

$$\theta_{t+1,i} = \theta_{t,i} - \eta g_{t,i} \quad (12)$$

而 AdaGrad 的更新方式为：

$$\theta_{t+1,i} = \theta_{t,i} - \frac{\eta}{\sqrt{\mathbf{G}_{t,ii} + \epsilon}} g_{t,i} \quad (13)$$

其中， $\mathbf{G}_t \in \mathbf{R}^{d \times d}$ 是一个对角矩阵，对角上的元素 i 为 θ_i 的历史值的平方和， ϵ 是为了防止分母为 0 的项，通常取值为 $1e-8$ ， η 通常不需要调整，默认值 0.01。

Ada Algs(2/3)-AdaDelta

Adadelata 对于 Adagrad 中的改进主要是采用一个固定窗口内的值的平方和的平均。第 t 步对应的值为：

$$E[g^2]_t = \gamma E[g^2]_{t-1} + (1 - \gamma)g_t^2 \quad (14)$$

同时有：

$$\Delta\theta_t = -\frac{\eta}{\sqrt{E[g^2]_t + \epsilon}}g_t \quad (15)$$

用新的记号 $RMS[g]_t$ 来重写上述分母，有：

$$\Delta\theta_t = -\frac{\eta}{RMS[g]_t}g_t \quad (16)$$

针对 η 的改进是：

$$\eta = RMS[\Delta\theta]_{t-1} = \sqrt{E[\Delta\theta^2]_{t-1} + \epsilon} \quad (17)$$

最终的表达式是：

$$\Delta\theta_t = -\frac{RMS[\Delta\theta]_{t-1}}{RMS[g]_t}g_t \quad (18)$$

$$\theta_{t+1} = \theta_t + \Delta\theta_t \quad (19)$$

Adaptive Moment Estimation:

$$\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1) \mathbf{g}_t \quad (20)$$

$$\nu_t = \beta_2 \nu_{t-1} + (1 - \beta_2) \mathbf{g}_t^2 \quad (21)$$


$$\hat{\mathbf{m}}_t = \frac{\mathbf{m}_t}{1 - \beta_1^t} \quad (22)$$

$$\hat{\nu}_t = \frac{\nu_t}{1 - \beta_2^t} \quad (23)$$

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\hat{\nu}_t} + \epsilon} \hat{\mathbf{m}}_t \quad (24)$$

其中, $\beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 10^{-8}$

Trend



(Source: Andrej Karpathy, 2017@Medium)

ML 中各种基于 gradient 优化的 variants 主要为了减少 noise 和利用二阶信息，而 DL 中的 variants 是为了改进学习率和解决 saddle point 而来。二阶优化方法是为了挖掘更多可利用信息，而一阶优化是为了更好的利用历史信息。

PSO v.s. Gradient Optimization

速度向量: $\nu_i = [\nu_i^1, \nu_i^2, \dots, \nu_i^D]$

位置向量: $x_i = [x_i^1, x_i^2, \dots, x_i^D]$

pBest: 粒子历史最优位置向量

gBest: 粒子群全局最优位置向量

更新公式:

$$\nu_i^d = \omega \nu_i^d + c_1 \text{rand}_1^d (pBest_i^d - x_i^d) + c_2 \text{rand}_2^d (gBest^d - x_i^d) \quad (25)$$

$$x_i^d = x_i^d + r \nu_i^d \quad (26)$$

惯性系数: $\omega = 0.9$, 学习率: c_1, c_2 , 随机数 $([0,1]): \text{rand}_1, \text{rand}_2$

Find minimum using PSO

- 初始化所有的个体 (粒子), 初始化他们的速度和位置, 并且将个体的历史最优值 $pBest$ 设置为当前位置, 而群体中最优的个体作为当前 $gBest$ 。
- 在每一代的进化中, 计算各个粒子的适应度函数值 (目标函数值)。
- 如果该粒子当前的适应度函数值比其历史最优值要好, 那么历史最优将会被当前位置所替代。
- 如果该粒子的历史最优比全局最优要好, 那么全局最优将会被该粒子的历史最优值所替代。
- 对每个粒子 i 的第 D 维的速度和位置按照 (25)(26) 进行更新。
- 如果还没有到达结束条件, 转到第二步, 否则输出 $gBest$ 并结束。

Pros and Cons(PSO)

1. 利用种群之间的个体比大小来寻找下降方向，适合目标函数含有较多局部极值的问题。
2. 为了保证种群多样性，在本种群更新的时候，来自其他种群的更好的解可能被舍弃掉。
3. 随着维度 D 的增加，新生个体比上一代好的比例急剧下降。(Adam P.Piotrowski, Applied Soft Computing, 2014)
4. DL 中对 saddle point 的处理效果有限。(Adam P.Piotrowski, Applied Soft Computing, 2014)

- Optimization Methods for ML&DL, Momentum, NAG, Adam, etc. How to make full use of gradient information?
- Schema about SGDs. How to use stochastic ideas?
- Optimization Methods in Distribution Setting. How to improve convergence, complexity and communication cost?

TKS(Q&R)